

1. Cálculo de determinação do grafo a ser utilizado

Regra de Mapeamento da Matrícula

De acordo com a regra de mapeamento determinada nas orientações do trabalho

Dado o número de matrícula M , e o cálculo determinado por:

$$f(M) = ((\text{soma dos dígitos de } M) \times (\text{últimos 2 dígitos de } M + 1)) \bmod 129$$

Matrícula : 224115861

Soma dos dígitos = 30

Últimos dois dígitos = 61

O resultado obtido foi de:

$$f(M) = ((30) \times (61 + 1)) \bmod 129 = 25$$

Conforme o ID da planilha **ANALISANDO-SNAP-DATASET**, o conjunto de dados correspondente é o “*LiveJournal social network and ground-truth communities*”, da categoria de redes sociais e comunidades ground-truth, que contém grafos do tipo comunidades e não direcionado.

A	B	C	D	E
ID	Category	Name	Name_URL	Type
25	Networks with ground-truth communities	com-LiveJournal	https://snap.stanford.edu/data/com-LiveJournal.html	Undirected, Communities

Figura 1 Seleção do dataset conforme a regra de mapeamento

Repositório

O repositório no github contém a documentação completa com os scripts, execução e relatório de desempenho anexado junto à documentação.

Consulte: (<https://github.com/Carolbalbs/tp-final>)

2. Descrição do grafo original

O conjunto de dados utilizado neste trabalho foi o com *LiveJournal social network and ground-truth communities*, disponibilizado pela coleção de redes do Stanford Network Analysis Project (SNAP) . é um dos maiores grafos não dirigidos publicamente disponíveis, com 3.997.962 milhões de nós e 3.997.962 milhões de arestas, representando usuários e conexões de amizade respectivamente.

O LiveJournal é uma plataforma de blogs e rede social online na qual os usuários podem estabelecer relações de amizade e participar de comunidades temáticas. O dataset representa essas relações de amizade através de um grafo não direcionado, além de fornecer informações sobre comunidades reais formadas pelos usuários. A computação exata de propriedades como diâmetro ou a aplicação de algoritmos com complexidade cúbica torna-se proibitiva em ambientes CPU convencionais.

Neste contexto, o uso de unidades de processamento gráfico (GPUs) surge como alternativa viável, graças à sua arquitetura massivamente paralela e à crescente maturidade de bibliotecas especializadas, como a suíte *RAPIDS* (*cuDF* e *cuGraph*). Este relatório detalha a metodologia adotada para responder às questões propostas nas Partes I, II e III do trabalho, especificando como cada métrica e algoritmo foi implementado, quais recursos computacionais foram empregados e como as incertezas amostrais foram quantificadas.

Arquivo	Conteúdo
com-lj.ungraph.txt	Grafo de amizade completo
com-lj.top5000.cmt.txt	Top 5000 comunidades
com-lj.all.cmt.txt	Todas as comunidades

Tabela 1. Informações sobre o dataset

O grafo analisado corresponde à maior componente conectada da rede, abrangendo praticamente toda a estrutura social disponível. Além disso, o dataset contém mais de 287 mil comunidades de referência (ground-truth communities), permitindo estudos relacionados à detecção e análise de comunidades.

Por se tratar de uma rede social em larga escala, o LiveJournal apresenta características típicas de redes complexas observadas em sistemas reais. Entre as estatísticas previamente reportadas para o dataset destacam-se aproximadamente 177 milhões de triângulos, além de:

Coefficiente médio de clusterização	$\approx 0,284$
Diâmetro igual	17
Diâmetro efetivo (90%)	$\approx 6,5$

Tabela 2. Informações estruturais disponíveis no site oficial

Esses indicadores sugerem uma estrutura altamente conectada, com forte tendência à formação de grupos de usuários e caminhos relativamente curtos entre pares de vértices, características frequentemente associadas a redes sociais online.

3. Metodologia

3.1. Dataset

O arquivo encontra-se no formato de lista de adjacências, com dois inteiros por linha, separados por tabulação.

3.2. Ambiente Computacional

Os experimentos foram conduzidos em um servidor integrado à infraestrutura do projeto BAMBU Lab – Rede Metropolitana para Experimentação e Inovação da Internet do Futuro. Este projeto, sediado na Universidade Federal da Bahia (UFBA) e com início em 2015, tem como objetivo a implantação de uma rede metropolitana de experimentação, dando suporte a práticas de ensino e pesquisa baianas.

O servidor conta com duas placas NVIDIA RTX A4000 (16 GB cada), sendo utilizada exclusivamente a GPU de índice 1 (via variável de ambiente `CUDA_VISIBLE_DEVICES=1`),

A configuração de software inclui:

- Sistema operacional: Linux (Ubuntu 22.04)
- CUDA: 12.6
- Driver NVIDIA: 560.35.03
- Python: 3.10
- Podman
- Ambiente Virtual com as bibliotecas:
 - *cuDF* / *cuGraph* (versão 24.xx) – para operações na GPU
 - *NetworkX* (versão 3.4) – para algoritmos não disponíveis em GPU
 - *NumPy*, *SciPy*, *Matplotlib* – para processamento estatístico e visualização
- Gerenciamento de memória: coleta explícita de lixo (`gc.collect()`) entre execuções para evitar vazamentos e interferências.

A escolha deste ambiente justifica-se pelo poder computacional oferecido pelas GPUs, que provê a infraestrutura de rede necessária para a manipulação eficiente de grandes volumes de dados, como milhões de arestas do grafo *LiveJournal* durante o experimento.

3.4 Análise Estrutural

Inicialmente, o dataset com-LiveJournal foi carregado utilizando RAPIDS cuGraph, com armazenamento em GPU. Após a leitura dos dados, foram removidos auto-laços e construída a representação do grafo em lista de adjacência.

As métricas estruturais básicas — número de vértices, número de arestas, distribuição de graus, grau mínimo, máximo, médio e mediano, densidade, componentes conexas, número de triângulos e coeficiente médio de clusterização — foram calculadas diretamente sobre o grafo completo utilizando algoritmos paralelizados em GPU.

Para as métricas relacionadas a caminhos mínimos (diâmetro, raio e comprimento médio dos caminhos), optou-se por uma abordagem de amostragem. O cálculo exato dessas medidas em uma rede com milhões de vértices apresenta custo computacional elevado. Dessa forma, foram selecionados 500 vértices aleatórios da maior componente conexa e executadas buscas

em largura (BFS) a partir de cada um deles. As distâncias obtidas permitiram estimar o diâmetro, o raio e o comprimento médio dos caminhos da rede.

Os valores estimados foram acompanhados por medidas estatísticas de dispersão e intervalos de confiança de 95%, fornecendo uma estimativa da precisão dos resultados.

3.3 Avaliação dos Algoritmos

Foram avaliados os algoritmos BFS, DFS, verificação de Eulerianidade, Dijkstra, Bellman-Ford, Floyd-Warshall, Tarjan, Prim e Kruskal.

Sempre que possível, utilizaram-se implementações em GPU por meio da biblioteca cuGraph, explorando o paralelismo oferecido pelo hardware. Algoritmos sem suporte adequado na GPU ou cuja execução se mostrou inviável no grafo completo foram executados em CPU utilizando a biblioteca NetworkX.

Devido à elevada complexidade computacional dos algoritmos Bellman-Ford e Floyd-Warshall, suas execuções foram realizadas sobre subgrafos contendo 1.000 vértices selecionados aleatoriamente, preservando a conectividade da amostra. Os demais algoritmos foram executados sobre o grafo completo.

3.4 Análise de Desempenho

Para cada algoritmo foram realizadas 30 execuções independentes. Em algoritmos que dependem de um vértice de origem, a fonte foi escolhida aleatoriamente a cada repetição.

Os tempos de execução foram registrados e utilizados para calcular média, desvio padrão e intervalo de confiança de 95%. Os resultados observados foram posteriormente comparados com as complexidades teóricas dos algoritmos, permitindo avaliar sua aplicabilidade em redes de larga escala como o LiveJournal.

3.3. Visualização

Geraram-se gráficos para apoiar a análise completa do grafo. Foram produzidos: (i) gráficos da distribuição de graus em escala log-log e das excentricidades amostradas, permitindo analisar a conectividade da rede e estimar diâmetro e raio; (ii) gráfico dos tempos médios de execução dos algoritmos, possibilitando a comparação entre implementações em CPU e GPU; e (iii) gráficos da distribuição de graus em escala log-log, além da comparação entre o coeficiente de clusterização observado e o esperado em um grafo aleatório equivalente, fornecendo evidências para a análise de lei de potência e da propriedade small-world.

4. Resultados obtidos

4.1 Tratamento do Dados

O dataset LiveJournal foi disponibilizado pelo SNAP já como grafo não direcionado e praticamente conexo. Os seguintes procedimentos foram aplicados antes das análises:

Leitura do arquivo de arestas via cuDF diretamente na memória da GPU, construindo a representação em lista de adjacência. Verificação de auto-laços: nenhum encontrado (0 removidos). Verificação de componentes desconectadas: o grafo é integralmente conexo (1 única componente). A maior componente conexa corresponde ao grafo completo (3.997.962 nós). Conversão para os formatos requeridos por cada algoritmo (cuGraph para GPU, NetworkX para CPU).

4.2 Tabelas e gráficos

Análise Estrutural

Métrica	Valor	Método
Número de vértices	3.997.962	Exato (GPU)
Número de arestas	34.681.189	Exato (GPU)
Grau mínimo	2	Exato (GPU)
Grau máximo	29.630	Exato (GPU)
Grau médio	34,6989	Exato (GPU)
Grau mediano	12,0	Exato (GPU)
Densidade	0,00000434	Exato (GPU)
Nº componentes conexas	1	Exato (GPU)
Tamanho LCC	3.997.962	Exato (GPU)
Diâmetro (LCC)	~16 (SNAP: 17)	Amostragem k=500
Raio (LCC)	~12	Amostragem k=500
Comprimento médio (LCC)	5,5592 ± 0,6265	Amostragem k=500
IC 95% comprimento médio	[5,5043; 5,6141]	Normal (n=500)
Coef. clusterização médio	0,061295	Exato (GPU)
Número de triângulos	177.820.130	Exato (GPU)

Tabela 3. Dados estruturais do Grafo Completo




Figura 2. Distribuição de graus (log-log) e histograma de excentricidades amostradas.

O gráfico de distribuição de graus em escala log-log revela uma curva com decaimento aproximadamente linear, característica de distribuições em lei de potência. A grande maioria dos usuários possui poucos amigos (grau mediano = 12), enquanto um número muito pequeno de hubs acumula milhares de conexões (grau máximo = 29.630). O histograma de excentricidades, obtido por amostragem de 500 nós, mostra que a maior parte dos nós possui excentricidade entre 13 e 15, com diâmetro estimado em 16 — próximo ao valor de referência do SNAP (17).

Algoritmos da Disciplina

Todos os algoritmos foram executados 30 vezes ($N=30$), permitindo uso da distribuição Normal para o IC 95% pelo Teorema do Limite Central. Dois algoritmos foram excluídos da análise de desempenho por apresentarem limitação estrutural com o grafo LiveJournal e são discutidos separadamente na seção 5.

Algoritmo	Complexidade	Média(ms)	IC 95%(ms)	Escopo
BFS	$O(V+E)$	48,34	[45,73; 50,95]	Grafo completo (GPU)
DFS	$O(V+E)$	26.679,76	[24.855,80; 28.503,72]	Grafo completo (CPU)
Eulerianidade	$O(V+E)$	1.533,44	[1.526,62; 1.540,26]	Grafo completo (CPU)
Bellman-Ford	$O(V \cdot E)$	4,40	[-0,39; 9,20]	Subgrafo 1.000 nós (CPU)
Floyd-Warshall	$O(V^3)$	74.191,24	[73.389,16; 74.993,33]	Subgrafo 1.000 nós (CPU)
Prim	$O(E \log V)$	438,98	[425,96; 451,99]	Grafo completo (GPU)
Kruskal	$O(E \log E)$	141.403,3 9	[136.142,28; 146.664,49]	Grafo completo (CPU)

Tabela 4. Análise de desempenho




Figura 3 — Tempo médio de execução dos algoritmos com IC 95% (escala logarítmica).

O gráfico evidencia três grupos de desempenho. Os algoritmos GPU no grafo completo (BFS: 48 ms, Prim: 439 ms) são significativamente mais rápidos que seus equivalentes CPU. Entre os algoritmos CPU no grafo completo, DFS (26.680 ms) e Kruskal (141.403 ms) são os mais lentos o que é esperado dado que não possuem implementação GPU e operam sobre 34M arestas. Os algoritmos em subgrafo (Bellman-Ford e Floyd-Warshall) apresentam tempos baixos em escala absoluta, mas são inviáveis no grafo completo pela escala de suas complexidades. Todos os ICs são estreitos exceto Bellman-Ford, refletindo a estabilidade das implementações GPU e a regularidade do grafo completo.

4.2 Small World

O grafo apresenta indícios de propriedade small-world?

O grafo apresenta fortes indícios de propriedade small-world. Visto que os dois critérios clássicos (Watts-Strogatz) foram satisfeitos:

Critério	Resultado	Condição
$C_{\text{real}} / C_{\text{random}}$	7344.26x	deve ser $\gg 1$
$L_{\text{real}} / L_{\text{random}}$	1.2970	deve ser ≈ 1
σ (sigma)	5662.29	deve ser > 1

Tabela 5. Propriedades small-world

O clustering real (0.063742) é **milhares de vezes maior** que o esperado num grafo aleatório equivalente (0.00000868), enquanto o caminho médio real (5.5592) é **quase idêntico** ao de um grafo aleatório (4.2860) — apenas ~30% maior. Essa combinação (clustering alto + caminhos curtos) é exatamente a assinatura small-world: o grafo não é nem totalmente regular (que teria clustering alto mas caminhos longos) nem totalmente aleatório (que teria caminhos curtos mas clustering baixo).

Faz sentido para seu grafo?

Com quase 4 milhões de nós e $\approx 34,7$ milhões de arestas, ter um caminho médio de apenas $\approx 5,5$ saltos é coerente com redes reais, que tipicamente exibem essa propriedade por causa de hubs e comunidades densamente conectadas internamente, mas interligadas por "atalhos" entre clusters. Sendo assim, coexistência de alto clustering local com baixo comprimento médio de caminho é, portanto, plenamente compatível com a interpretação de que a rede combina estrutura comunitária densa, proximidade temática ou interação social. Esse padrão é amplamente documentado em redes empíricas de naturezas variadas, incluindo redes sociais, redes de citação, redes biológicas e a própria topologia da web.

Qual é a implicação prática de ser small-world?

Nesse aspecto, a propriedade small-world possui implicações relevantes para a dinâmica de informação, influência, doenças ou falhas se propagam muito rapidamente pela rede (poucos saltos conectam quaisquer dois nós, em média), mesmo que a rede seja localmente muito "agrupada" (vizinhos tendem a se conectar entre si, formando comunidades coesas). Isso tem impacto direto em:

- **Difusão/viralização** — conteúdo ou epidemias se espalham rápido (baixo L)
- **Robustez/comunidades** — a estrutura local densa (alto C) mantém subgrupos coesos, resilientes a perda de arestas internas
- **Busca e roteamento** — algoritmos de navegação (ex: busca gulosa) tendem a funcionar bem, pois poucos saltos bastam para alcançar qualquer nó

4. Lei de potência

A distribuição de graus sugere uma lei de potência?

A distribuição de graus do LiveJournal segue lei de potência com $\gamma \approx 2,44$. Isso gera naturalmente uma distribuição de graus em lei de potência: a maioria dos usuários tem poucos amigos (grau mediano = 12), enquanto um número muito pequeno de usuários acumula milhares de conexões (grau máximo = 29.630). Esses hubs existem porque a plataforma de blogs incentiva que usuários populares (blogueiros influentes) acumulem seguidores ao longo do tempo.

Para verificar se $P(k) \sim k^{-\gamma}$, seguiu-se o procedimento do Apêndice B: (1) calculou-se a distribuição de graus de todos os vértices; (2) construiu-se o histograma e o CCDF; (3) plotou-se em escala log-log; (4) ajustou-se uma reta via regressão OLS — se o gráfico log-log for aproximadamente linear, a distribuição segue lei de potência.




Figura 4. Distribuição de graus e Lei de potência

O gráfico PDF log-log (Figura 3, painel esquerdo) mostra que os pontos empíricos se alinham aproximadamente sobre a reta ajustada em praticamente toda a extensão de k , do grau mínimo (2) ao máximo (29.630). O ajuste por regressão OLS sobre $\log P(k)$ vs $\log k$ retornou:

4. Robustez

Métrica	Baseline	Remoção aleatória (5%, T=30)	Remoção de hubs (5%, degree)
A - fração da LCC	1,0000	0,9385 $\pm$ 0,0001	0,8912 ($\Delta=-0,1088$)
B - nº de componentes	1	2.705,6 $\pm$ 62,5	11.174 ($\Delta=+11.173$)
C - distância média	5,6753	5,6057 $\pm$ 0,0704	7,3709 ($\Delta=+1,6956$)
D - fração de isolados	0,000000	0,000000 $\pm$ 0,000000	0,000000

Tabela 6. Métricas de Análise da Robustez




Figura 5. Análise de Robustez do Grafo

A Figura 4 torna a assimetria entre os dois tipos de ataque visualmente inequívoca: nos painéis A e C, o ponto da remoção de hubs cai completamente fora do intervalo observado nas 30 repetições aleatórias, revelando uma separação categórica. O painel B a escala do eixo precisa se estender a mais de 11 mil para acomodar o resultado da remoção de hubs, fazendo a faixa de variação da remoção aleatória (~2.600 - 2.850 componentes) parecer quase um ponto fixo por comparação.

O grafo é robusto à:

a. Remoção aleatória de 5% dos vértices

Sim, o grafo é robusto devido a falhas aleatórias. Remover 5% dos vértices ao acaso reduz a maior componente em apenas 6,15% (de 1,0000 para 0,9385), e o desvio padrão entre as 30 repetições é praticamente nulo ($\pm 0,0001$), indicando que o resultado não depende de quais vértices foram sorteados, é uma propriedade estrutural estável da rede. A distância média praticamente não se altera (5,6753 - 5,6057).

b. Remoção dos 5% mais centrais

Com o mesmo percentual de remoção (5%), podemos perceber que o grafo é torna-se vulnerável a **ataques direcionados aos hubs**. Os três sinais de dano pioram simultaneamente: a LCC cai quase o dobro (10,88% vs. 6,15%), o número de componentes explode para 11.174, mais de 4× a

fragmentação do cenário aleatório, além disso a distância média **de fato cresce** ~30% (5,6753 - 7,3709), ao contrário do cenário aleatório. Isso é coerente com a teoria: hubs funcionam como atalhos estruturais; removê-los força os caminhos remanescentes a contornar por rotas mais longas.

Comparação S_{rand} vs. S_{cent}

1. $S_{rand} = 0,938 \gg S_{cent} = 0,891$ - Mostra que a LCC é significativamente maior após remoção aleatória

2. $c_{rand} \approx 2.706 \gg c_{cent} = 11.174$ - a fragmentação é $4,1\times$ maior após remoção dos hubs

Assim, ambas as condições são satisfeitas, conforme o critério do Apêndice C, a rede é muito **vulnerável** a ataques direcionados e **robustos** a falhas aleatórias, padrão típico de redes com lei de potência (scale-free).

4. Descobertas

A dicotomia robustez/vulnerabilidade em redes scale-free

A maior descoberta deste trabalho foi o entendimento acerca dos comportamentos característicos de redes scale-free, aproximando-se da dicotomia prevista teoricamente em modelos clássicos por Barabási e Albert (2000): redes scale-free são simultaneamente as mais robustas a falhas aleatórias e as mais vulneráveis a ataques direcionados.

Os dados preliminares de robustez (baseline $A=1,0000$, $C=5,459$) já apontam para esse padrão. Remover 5% dos hubs de maior grau — apenas ~200 mil nós dentre 4 milhões — deve fragmentar significativamente a maior componente conexa, enquanto a remoção aleatória dos mesmos 5% causa degradação muito menor. Isso acontece porque os hubs do LiveJournal concentram uma fração desproporcional das conexões: o grau máximo observado foi 29.630, contra uma mediana de apenas 12.

Validação cruzada com o SNAP

A contagem exata de triângulos (177.820.130) coincidiu perfeitamente com o valor reportado pelo SNAP, servindo como validação de corretude da implementação em GPU. O diâmetro estimado (16) está a apenas 1 unidade do valor de referência (17), e o comprimento médio estimado (5,559) está dentro do intervalo reportado pelo SNAP (diâmetro efetivo de 90% $\approx 6,5$).

5. Discussão crítica

Decisões de projeto e justificativas

Diâmetro, raio e comprimento médio foram estimados por amostragem de $k=500$ nós em vez de cálculo exato. O cálculo exato exigiria $\sim 1,55 \times 10^{14}$ operações (~ 43 horas na GPU RTX A4000), inviável no escopo do trabalho. Sem GPU, este trabalho seria inviável em tempo razoável. A comparação BFS GPU (48 ms) versus DFS CPU (26.680 ms), ambos $O(V+E)$, evidencia uma aceleração de $\sim 553\times$ para operações com mesma complexidade teórica.

Todavia, nem todos os algoritmos beneficiam-se igualmente da GPU. Algoritmos com estruturas de dados complexas ou dependências sequenciais (como DFS) não possuem implementações paralelas eficientes, optando-se pela CPU. Da mesma forma, algoritmos com complexidade quadrática ou cúbica (Bellman-Ford, Floyd-Warshall) permanecem inviáveis mesmo em GPU para o grafo completo, exigindo a redução do escopo.

Limitações metodológicas

A avaliação dos nove algoritmos da Parte II revelou dois tipos distintos de limitação em relação ao grafo analisado, que merecem ser diferenciados explicitamente

As limitações estruturais dizem respeito à natureza do grafo não ponderado e não direcionado. Assim, os algoritmos Dijkstra (pressupõe pesos nas arestas) e Tarjan (restrito a grafos dirigidos), embora tenham sido executados durante a realização dos experimentos não foram incluídos na comparação de desempenho.

Para as limitações computacionais, a execução em subgrafo de 1.000 nós construído por Bellman-Ford e Floyd-Warshall foram executados em subgrafo de 1.000 nós por inviabilidade computacional no grafo completo ($O(V \cdot E)$ e $O(V^3)$ respectivamente). Os tempos medidos refletem o comportamento dos algoritmos em escala reduzida e não são diretamente extrapoláveis ao grafo completo. O IC negativo do Bellman-Ford ($[-0,39; 9,20]$ ms) indica alta variância nas medições e deve ser interpretado como limite inferior a zero.

A robustez foi analisada com $T=30$ repetições para a remoção aleatória, permitindo quantificar a variabilidade estatística via boxplot (Apêndice C). A centralidade de grau foi escolhida por ser calculável em $O(1)$ por nó no cuGraph, ao contrário do betweenness ($O(V \cdot E)$) que seria proibitivo para 4M nós.

6. Conclusão

Este trabalho analisou a rede social LiveJournal — com 3.997.962 vértices e 34.681.189 arestas — sob três perspectivas complementares: estrutural, algorítmica e analítica avançada. A execução foi viabilizada pelo uso de GPUs NVIDIA RTX A4000 via biblioteca cuGraph, que permitiu calcular métricas como contagem de triângulos (177.820.130, exato em 0,9 s) e BFS em toda a LCC (48 ms por BFS) que seriam inviáveis em CPU convencional.

Os principais resultados foram:

- O grafo é completamente conexo (1 componente), esparso (densidade $4,34 \times 10^{-6}$) e apresenta distribuição de graus heterogênea (mín=2, máx=29.630, mediana=12).
- A rede possui propriedade small-world confirmada ($\sigma=5.662$): clustering $7.344\times$ maior que o esperado em grafo aleatório equivalente, com distâncias médias de apenas 5,6 saltos.
- A distribuição de graus segue lei de potência com $\gamma \approx 2,44$ ($R^2=0,924$), confirmando a natureza scale-free e a presença de hubs com milhares de conexões.
- Entre os algoritmos avaliados, a aceleração GPU foi determinante: BFS GPU (48 ms) foi $553\times$ mais rápido que DFS CPU (26.680 ms) para grafos com mesma complexidade teórica $O(V+E)$. Dijkstra GPU (111 ms) e Prim GPU (439 ms) também demonstraram desempenho superior ao equivalente CPU.
- A análise de robustez confirmou a dicotomia scale-free: a rede é resistente a remoções aleatórias mas vulnerável a ataques direcionados nos hubs.

Do ponto de vista prático, os resultados têm implicações diretas para moderação de conteúdo, campanhas de saúde pública e segurança de redes: dado que a rede é small-world e scale-free, intervenções focadas nos ~200 mil usuários mais conectados (5% do total) têm impacto desproporcional sobre a conectividade global, seja para conter desinformação, seja para disseminar informações de saúde.

Como trabalho futuro, sugere-se: (i) o cálculo exato do diâmetro via algoritmos de double sweep ou iFUB em GPU; (ii) análise exploratória das redes de comunidades ground-truth e top 5000 communities disponíveis no dataset (<https://snap.stanford.edu/data/com-LiveJournal.html>);

Referências

- *RAPIDS cuGraph*: <https://rapids.ai/cugraph>
- *NetworkX*: <https://networkx.org>
- *SNAP Datasets*: <https://snap.stanford.edu/data>
- J. Yang and J. Leskovec. *Defining and Evaluating Network Communities based on Ground-truth*. ICDM, 2012.